

# 基于深度学习的短时交通流预测<sup>\*</sup>

罗向龙, 焦琴琴<sup>†</sup>, 牛力瑶, 孙壮文  
(长安大学 信息工程学院, 西安 710064)

**摘要:** 针对现有预测方法未能充分揭示交通流内部的本质规律, 提出了一种基于深度学习的短时交通流预测方法。该方法结合深度信念网络模型(DBN)与支持向量回归分类器(SVR)作为预测模型, 利用差分去除交通流数据的趋势项, 用深度信念网络模型进行交通流特征学习, 在网络顶层连接支持向量回归模型进行流量预测。实际交通流数据测试结果表明, 提出的预测模型与传统预测模型相比具有更高的预测精度, 预测性能提高了18.01%, 是一种有效的交通流预测方法。

**关键词:** 交通流预测; 深度学习; 短时交通流; 支持向量回归

中图分类号: TP181 文献标志码: A 文章编号: 1001-3695(2017)01-0091-03

doi: 10.3969/j.issn.1001-3695.2017.01.018

## Short-term traffic flow prediction based on deep learning

Luo Xianglong, Jiao Qinqin<sup>†</sup>, Niu Liyao, Sun Zhuangwen  
(School of Information Engineering, Chang'an University, Xi'an 710064, China)

**Abstract:** In view of the existing prediction methods fail to fully reveal the nature of the traffic flow, this paper proposed a short-term traffic flow prediction model based on deep learning. The method combined the deep belief network (DBN) model and support vector regression (SVR) classifier as predictive model. It removed the trend of the traffic flow by using data difference, extracted traffic flow features by deep belief network model, carried and the traffic flow prediction out with support vector regression in the top level of the network. Experiment results with actual traffic flow data show that the proposed method has a higher accuracy compared with others, prediction performance increases by 18.01%, and it is an effective traffic flow prediction method.

**Key words:** traffic flow prediction; deep learning; short-term traffic flow; support vector regression

## 0 引言

交通流预测是交通管理和控制部门采取交通诱导措施的主要依据, 是智能交通系统研究的核心问题。为了更好地实时性反映交通状态, 基于短时交通流量预测模型的研究成为近几十年来流量预测研究的重点。随着新技术的不断发展及智能化系统的广泛应用, 对于大数据的处理和交通预测模型的精度提出了更高的要求。实时、准确的交通流预测, 可以有效地提高交通的通行效率和安全性, 并且方便管理部门主动进行交通规划, 并采取合理的交通诱导措施。

已有的短时交通流预测模型主要有基于时间序列的统计模型、概率图模型、非参数预测模型和混合组合模型等。Xue 等人<sup>[1]</sup>在混沌时间序列分析方法的基础上, 提出了一种两步优化选择方法的交通流预测模型, 综合考虑了相邻节点与预测点之间的欧几里德距离系数; Zhang 等人<sup>[2]</sup>提出了一种基于频谱分析和统计波动理论的混合短时交通流预测方法, 应用频谱分析把交通数据分解成三种不同的频率成分, 进而采用不同预测模型进行流量预测; 傅贵等人<sup>[3]</sup>通过引入核函数把交通流预测问题转换为高维空间的线性回归问题, 提出了基于支持向量机回归的短时交通流预测模型; Wang 等人<sup>[4]</sup>提出了一种新的贝叶斯组合预测方法, 通过基于熵的灰度关联性分析

了历史流量之间的相关性, 将三种不同预测模型相结合来进行短时交通流预测; Kumar 等人<sup>[5]</sup>应用了人工神经网络的短时交通流预测模型。这些预测模型虽然提高了预测的精确性, 但都只是在传统预测模型的基础上进行了改进, 而没有考虑道路网络当中交通状况之间的时间—空间相关性。

为了更好地反映交通状况, Yang 等人<sup>[6]</sup>提出了一种基于空间关系的最小二乘支持向量回归预测模型; Xu 等人<sup>[7]</sup>提出基于时空特性的贝叶斯多元回归自适应样条模型进行交通流预测, 该模型具有更强的可解释性和适应性; 李颖宏等人<sup>[8]</sup>考虑了交通流的时间空间性, 提出了基于组合模型的交通流预测; Wu 等人<sup>[9]</sup>提出了短期交通流预测的改进 K-近邻预测模型, 并且针对预测的不同节点和不同时段检验其适用性。然而对于改进的这些算法虽然考虑了交通流之间的时间—空间特性, 并且取得了较好的预测精度, 但面对巨大的交通数据的处理, 没有挖掘出数据本质的特征。例如神经网络、支持向量回归等预测模型等均属于浅层模型, 在有限的样本和计算单元的条件下, 对复杂函数的表达能力有限, 泛化能力受到了限制; 且大量样本的数据特征的选择都是根据特定领域的先验知识, 并不能完全反映数据的本质特征。

近年来深度学习作为一种新的机器学习方法开始受到研究人员和商业人士的高度关注。深度学习结构是一个包含多

收稿日期: 2015-10-27; 修回日期: 2015-12-15 基金项目: 国家交通运输部重大科技专项项目(201318812260)

作者简介: 罗向龙(1978-), 男, 陕西西安人, 副教授, 博士, 主要研究方向为智能交通、信号处理; 焦琴琴(1990-), 女(通信作者), 甘肃天水人, 硕士, 主要研究方向为机器学习、信号处理(qin\_jxx32@163.com)。

隐层的多层感知器,通过学习一种深层的非线性网络结构来实现复杂函数的逼近。针对大数据,深度学习能够通过底层的特征组合,抽象高层特征来实现数据的分布式表示,从而可以更好地刻画出数据的本质特征。Hinton 等人<sup>[10]</sup>提出了基于深度信念网络的快速学习算法,并应用于数字图形识别。深度学习现已在分类问题中得到了成功的应用,如人类语言识别、图像分类、目标检测等<sup>[11-12]</sup>。此外,Kuremoto 等人<sup>[13]</sup>应用了基于限制波尔兹曼机的深信网络模型的时间序列预测。目前应用深度学习来进行交通预测的文章还比较少,Huang 等人<sup>[14]</sup>应用了基于深信网络模型结构和多任务回归的交通预测方法,对单输出和多任务输出的流量进行了预测;Lyu 等人<sup>[15]</sup>针对大路网下的交通流,提出了自编码的深度网络模型预测方法。这两种方法采用的顶层预测模型均为对数回归模型,未考虑交通数据潜在的趋势向对预测结果的影响。

针对现有交通流预测方法的不足,本文提出了基于深度信念网络模型(deep belief network, DBN)的短时交通流预测模型。本文首先利用差分原理对输入的交通流数据进行预处理来消除数据趋势向;然后通过深度信念网络模型对输入数据进行特征学习,经过无监督的逐层特征训练和有监督的参数微调,抽象出交通流的本质规律;最后以此作为新的训练和测试样本输入顶层的支持向量回归模型进行预测,对预测结果进行反差分得到预测路段的交通流量预测值。

## 1 深度学习

深度学习是一种无监督的特征学习过程,通过采用自下而上的无监督逐层训练来学习特征,再应用由上而下的有监督训练来微调整个网络参数。深度学习的主要思想是实现数据的分级表达,寻找大量数据的本质特征。目前的深度学习网络模型有深度信念网络模型(DBN)、深度神经网络模型(CNN)、稀疏自动编码模型(SAE)和降噪自动编码模型(DAE)。DBN 模型是深度学习中常用的一种网络模型,是由多个限制波尔兹曼机(RBM)模型的叠加,每个 RBM 都是只包含一个隐层的两层模型,每一个 RBM 的训练输出作为下一个 RBM 的输入。

### 1.1 限制波尔兹曼模型

限制波尔兹曼机(restricted Boltzmann machine, RBM)<sup>[16]</sup>是一个两层的无向图模型,如图 1 所示。给予给定的可见层与隐层单元之间为任意的指数分布,假设所有的隐层单元和可见层单元均为二值分布,设隐层单元为  $h$ ,可见层单元为  $v$ ,即  $\forall i, j, v_i \in \{0, 1\}, h_j \in \{0, 1\}$ 。假定隐层和可见层的单元数目分别为  $m, n$ ,则对于给定的一组状态  $(v, h)$ , RBM 的能量公式为

$$E(v, h | \theta) = - \sum_{i=1}^n a_i v_i - \sum_{j=1}^m b_j h_j - \sum_{i=1}^n \sum_{j=1}^m w_{ij} v_i h_j \quad (1)$$

其中:  $\theta = \{w_{ij}, a_i, b_j\}$  是 RBM 的参数;  $w_{ij}$  是可见层单元  $i$  与隐层单元  $j$  之间的连接权值;  $a_i$  表示可见单元的偏置;  $b_j$  表示隐层单元的偏置。基于这个能量函数,可以得出这组状态  $(v, h)$  的联合概率分布为

$$P(v, h | \theta) = \frac{e^{-E(v, h | \theta)}}{Z(\theta)} Z(\theta) = \sum_v e^{-E(v, h | \theta)} \quad (2)$$

其中:  $Z(\theta)$  为归一化因子。由此可以得出  $v$  的分布  $P(v | \theta)$ , 即联合概率分布  $P(v, h | \theta)$  的边缘分布为

$$P(v | \theta) = \frac{1}{Z(\theta)} \sum_h e^{-E(v, h | \theta)} \quad (3)$$

由 RBM 的结构性质可以得出,给予给定的可见单元(或

隐层单元),各个隐层单元(或可见单元)的激活状态之间是相互独立的,则第  $j$  个隐层单元和第  $i$  个可见单元的激活概率分别为

$$P(h_j = 1 | v, \theta) = \sigma(b_j + \sum_i v_i w_{ij}) \quad (4)$$

$$P(v_i = 1 | h, \theta) = \sigma(a_i + \sum_j w_{ij} h_j) \quad (5)$$

其中:  $\sigma(x) = \frac{1}{1 + \exp(-x)}$  为 sigmoid 函数。

### 1.2 DBN 模型

多个 RBM 模型通过自底向上组合形成一个 DBN。DBN 模型的训练过程可以看做是一个逐层特征提取过程,经过每一层训练后的输出都是输入特征的非线性变换。基于 Hinton<sup>[17]</sup>提出的 RBM 快速学习算法,即对比散度(contrastive divergence)来进行训练数据,进而对各参数进行更新。多个 RBM 模型训练完成后,再在顶层连接一个支持向量回归(SVR)预测器用来预测流量。设 DBN 模型的层数为  $K$  层,每层的节点数为  $N_i (i = 1, 2, \dots, K)$ 。

## 2 基于 DBN-SVR 的交通流预测模型

### 2.1 时间序列预处理

交通流数据本身是一种非平稳随机序列,但在连续的时间序列上表现出一定的规律性,并且具有明显的趋势向。SVR 模型能够很好地处理非线性数据,但对于具有明显趋势向的时间序列的处理能力较差,因此,这种趋势向会影响交通流预测的精度。为了提高预测的准确性,本文采用了一种新的数据平滑方法<sup>[18]</sup>来消除趋势向。设原始交通流时间序列数据为  $x(t)$ ,处理后的数据为  $x^d(t)$ ,处理过程描述如式(6)所示。

$$x^d(t) = x(t) - x(t-d) \quad (6)$$

其中:  $d$  为时间序列的延迟时间,  $x^d(t)$  作为新的输入样本来预测  $x^d(t+1)$  的值。通过训练以后,得到了新的时间序列在下一时刻的预测值  $\hat{x}^d(t+1)$ ,则最终的原始数据的预测结果为

$$\hat{x}(t+1) = \hat{x}^d(t+1) + \hat{x}(t-d+1) \quad (7)$$

### 2.2 DBN-SVR 交通流预测模型

给予一个给定的路段,设交通流数据的采样时间间隔为  $\Delta t$ ,采集的观测数据数目为  $N$ ,选择的观测断面数为  $p$ ,则路段中所有断面的交通流数据组成一个流量数据集,可以表示为

$$A = \{x_1, x_2, \dots, x_p\} \quad (8)$$

$$x_i = \{x_{i,1}, x_{i,2}, \dots, x_{i,d}\} \quad (9)$$

其中:  $i = 1, 2, \dots, p$ ;  $x_i$  表示某一个断面在不同时刻的交通流。

由于各个断面的交通流之间具有时间、空间上的关联性,设预测模型的输入数据集为  $X$ ,则有

$$X = \{x_1, x_2, \dots, x_p\} \quad (10)$$

$$x_i = (x_{i,t}, x_{i,t-\Delta t}, \dots, x_{i,t-M\Delta t}) \quad (11)$$

其中:  $i = 1, 2, \dots, p$ ;  $x_{i,t}$  表示第  $i$  个断面在  $t$  时刻的交通流量。任意一个断面的下一时刻的流量由各个断面当前时刻和前  $M$  个时刻的流量来预测。假设输入数据集经过 DBN 模型特征学习后的输出向量为  $H$ ,则有

$$H = \Phi(X_d) \quad (12)$$

其中:  $\Phi$  表示深度学习模型,本文采用 DBN 网络模型;  $X_d$  为按照式(6)处理后的交通流数据集。由此得出任意一个断面  $j$  在  $t + \Delta t$  时刻的交通流预测值为

$$y_d(j, t + \Delta t) = f(H) \quad (13)$$

其中:  $f$  为一种预测模型, 文中采用 SVR 模型;  $y_d(j, t + \Delta t)$  为第  $j$  个断面在  $t + \Delta t$  时刻的交通流,  $j = 1, 2, \dots, p$ 。

具体的交通流预测算法流程如下: a) 根据交通流数据特征, 根据式 (10) (11) 构造输入数据集  $X$ ; b) 根据式 (6) 对交通流数据集进行差分预处理得到  $X_d$ ; c) 以  $X_d$  作为 DBN 网络模型输入进行特征学习, 由式 (12) 得到交通流特征  $H$ ; d) 以  $H$  为输入, 利用 SVR 预测模型进行流量预测; e) 由式 (7) 进行反差分计算, 求出交通流预测值。

### 3 实验仿真

#### 3.1 数据来源和仿真结果

本文实验数据来源于美国加利福尼亚运输部的性能测量系统 (PeMS) 数据库。对 Orange Country 区域内的标号为 15-N 这条高速公路的 25 个断面进行采样 ( $p = 25$ ), 总共有 108 个检测器。数据采样时间间隔为 5 min。随机选取其中的 16 个断面的数据作为实验数据。交通流数据具有一定的规律性, 并且周末和非周末呈现出不同的数据特性。为充分利用其数据之间的规律性, 本文针对高速公路交通流数据 (不包含周末) 进行预测评估, 并以实际数据进行了验证。以 2014 年 6 月份 (6.2 ~ 6.29) 非周末的数据作为训练数据集, 以 2014 年 7 月份 (7.1 ~ 7.14) 两周 10 天的数据 (不包含周末) 作为测试数据集, 总共有 5 680 个训练样本和 2 840 个测试样本, 以此作为模型的输入。

本文中所采用的 DBN 模型的层数和时间间隔的确定是根据文献 [14] 取得, 层数设定为  $K = 3$ , 时间间隔  $M = 4$ 。差分延迟的取值设定为  $d = \{2, 3, 4, 5, 6, 7, 8, 9, 10\}$ , 输出节点数的起始值设定为 5, 并以步长为 5 来逐渐增加。在反复实验的过程中发现, 当  $N$  的取值大于 40 时, 均方误差的值不再发生变化, 所以  $N$  的上限值为 40, 最后输出层的节点数  $N = \{5, 10, 15, 20, 25, 30, 35, 40\}$ 。遍历所有的延迟时间间隔和输出节点数, 根据交通流预测模型的步骤, 反复迭代实验, 求出使得均方误差最小的时延间隔和输出节点数, 即最佳的时延间隔  $d = 5$ , 节点数目  $N = 30$ 。图 2 为不同的延迟时间间隔和不同的节点数与预测的均方误差关系图。DBN 模型训练的迭代次数为 50。顶层采用的 SVR 预测模型的参数设置分别为: SVR 核函数为 RBF (径向基), 惩罚因子  $C = 0.01$ , 迭代次数为 10 000。图 3 为预测路段的一天交通流预测值和实际值的对比结果。

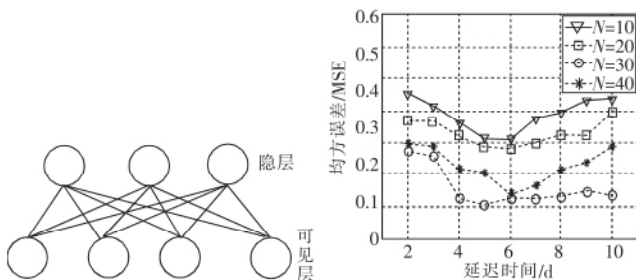


图 1 RBM 模型图




图 2 延迟间隔和节点数对均方误差的影响

由图 3 可以看出, 本文提出的预测模型的预测结果与实际交通流数据偏差很小, 反映了交通流随时间变化的基本规律, 特别是对高峰时段交通流数据吻合良好。

为了进一步验证本文提出的预测模型的有效性, 图 4 给出了连续两周的交通流预测结果。从图 4 中可以看出, 交通流数据具有很强的规律性, 预测值与实际值之间基本重合, 误差较

小, 充分证明了本文所用的预测模型的可行性、有效性。




图 3 预测值与实际值的对比结果

图 4 两周交通流预测结果

#### 3.2 误差分析及比较

为了更好地分析预测效果, 本文分别计算了均方误差 (MSE)、平均绝对百分比误差 (MAPE) 两种误差评价指标, 这两种方法的定义分别为

$$MSE = \frac{1}{N} \sqrt{\sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (14)$$

$$MAPE = \frac{1}{N} \sum_{i=1}^N \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\% \quad (15)$$

文中用 2014 年 7 月份两周的数据作为测试样本, 分别对于 NN、SVR 和本文提出的预测模型的性能进行了比较和分析, 由式 (14) (15) 分别计算了这三种模型预测结果的 MSE 和 MAPE 结果如表 1 所示。由表 1 可以得出, 本文提出的预测模型的误差性能明显优于传统的基于浅层模型的 NN 和 SVR 模型, 表明了深度学习在交通流预测中的有效性。

表 2 分别给出了对交通流数据进行差分处理前后应用 DBN-SVR 模型进行预测的误差。从表 2 可看出, 经过差分处理后, 可明显改善预测的精确性, 充分说明了趋势向对预测结果可靠性的影响, 表明本文方法是一种有效的交通流预测方法。

表 1 预测模型结果分析

预测模型	评价指标	
	MSE	MAPE/%
DBN-SVR	0.102 4	5.959 2
SVR	0.124 9	6.091 4
NN	0.140 8	13.547

表 2 差分对预测结果的影响

数据形式	评价指标	
	MSE	MAPE/%
差分数据	0.102 4	5.959 2
非差分数据	6.105 3	28.290 0

### 4 结束语

本文提出了一种应用深信网络模型结合支持向量回归的短时交通流预测方法, 利用 DBN 模型对路网中的交通流数据进行特征学习, 从而挖掘出数据的本质特征, 然后采用支持向量回归 (SVR) 预测器进行流量预测。实测交通流数据验证的结果表明, 本文提出的预测模型预测值和真实值吻合效果良好, 预测精度高, 是一种有效的交通流预测方法。但所用 DBN 是深度学习中最常用的一种模型, 在将来的研究中还应考虑其他更有效的深度模型。此外, 本文只是对于路段中的单个断面的输出进行预测, 多断面输出预测还需要进一步研究。

#### 参考文献:

- [1] Xue Jieni, Shi Zhongke. Short-time traffic flow prediction based on chaos time series theory [J]. Journal of Transportation Systems Engineering and Information Technology 2014, 8(5): 68-72.
- [2] Zhang Yanru, Zhang Yunlong, Haghani A. A hybrid short-term traffic flow forecasting method based on spectral analysis and statistical volatility model [J]. Transportation Research Part C: Emerging Technologies 2014, 43(1): 65-78.
- [3] 傅贵, 韩国强, 遼峰, 等. 基于支持向量机回归的短时交通流预测模型 [J]. 华南理工大学学报 2013, 41(9): 71-76.

(下转第 97 页)

PBD 活性检测精度进行对比, 实验结果如图 10 所示。




图10 预测精度对比

从图 10 可以看出, 随着数据级的增大, SVM 和 ANN 精度预测结果出现明显波动, DBN 网络预测精度逐渐趋于稳定, 当数据规模达到 15 000 以后, DBN 网络预测精度基本不再发生变化, 其平均预测值为 91.05%, 可见 DBN 网络预测结果稳定且精度较高。同时, 为了针对 PLK1 PBD 活性进行综合性研究, 本文又将测试数据分为原始表述、2D 表述和 3D 表述三组, 以此作为输入集进行 DBN 性能检测, 如图 11 所示。




图11 预测精度对比

由图 11 可知, 基于 DBN 模型的 PLK1 PBD 活性预测在不同的数据表述中皆体现出较好的稳定性和较高的识别度, 这是由于 DBN 网络采取的是概率性逐层贪婪学习过程, 根据自下向上迭代训练, 对神经网络权值和阈值进行优化处理, 从而保留较好的结果。

### 3 结束语

对 PLK1 PBD 活性定量构效关系进行研究是当前的热点, 面对日益严峻的健康安全问题, 在限定的数量样本研究中能够高效处理数据内部关系是本文研究的重点。实验结果表明, 采用 DBN 模型对 PLK1 PBD 活性的预测误差小, 与实际值拟合度高, 训练收敛迅速, 预测结果精度明显优于 SVM 和 ANN。未来可以选择不均样本或者大规模样本进行实验, 加强 DBN 网络模型的实用性。

### 参考文献:

- [1] Zhang Zhe, Chen Long, Wang Hexiang *et al.* Inhibition of PLK1 represses androgen signaling pathway in castration-resistant prostate cancer [J]. *Cell Cycle* 2015, 14(13): 2142-2148.
- [2] Strebhardt K. Multifaceted polo-like kinases: drug targets and antitargets for cancer therapy [J]. *Nature Reviews Drug Discovery*, 2010, 9(8): 643-660.
- [3] De Cárcer G, Manning G, Malumbres M. From PLK1 to PLK5: functional evolution of polo-like kinases [J]. *Cell Cycle* 2011, 10(14): 2255-2262.
- [4] Li Hongguang, Chan Chifai, Chan Wailun *et al.* Monitoring and inhibition of PLK1: amphiphilic porphyrin conjugated PLK1 specific peptides for its imaging and anti-tumor function [J]. *Organic & Biomolecular Chemistry* 2014, 12(31): 5876-5882.
- [5] Prystowsky M, Feeney K, Kawachi N *et al.* Inhibition of PLK1 and cyclin B1 expression results in panobinostat-induced G<sub>2</sub> delay and mitotic defects [J]. *Scientific Reports* 2013, 3(2640): 274.
- [6] McInnes C, Estes K, Baxter M *et al.* Targeting subcellular localization through the polo-box domain: non-ATP competitive inhibitors recapitulate a PLK1 phenotype [J]. *Molecular Cancer Therapeutics*, 2012, 11(8): 1683-1692.
- [7] Garuti L, Roberti M, Bottegoni G. Polo-like kinases inhibitors [J]. *Current Medicinal Chemistry* 2012, 19(23): 3937-3948.
- [8] Liu Fa, Park J E, Qian Wenjian *et al.* Serendipitous alkylation of a PLK1 ligand uncovers a new binding channel [J]. *Nature Chemical Biology* 2011, 7(9): 595-601.
- [9] Salahinejad M, Ghasemi J B. 3D-QSAR studies on the toxicity of substituted benzenes to tetrahymena pyriformis: CoMFA, CoMSIA and VolSurf approaches [J]. *Ecotoxicology Environmental Safety*, 2014, 105: 128-134.
- [10] Ch'ng S I, Seng K P, Ang L M. Block-based deep belief networks for face recognition [J]. *International Journal of Biometrics*, 2012, 4(2): 130-143.
- [11] Yu Dong, Deng Li. Deep learning and its applications to signal and information processing [J]. *IEEE Signal Processing Magazine* 2011, 28(1): 145-154.
- [12] Sarikaya R, Hinton G E, Deoras A. Application of deep belief networks for natural language understanding [J]. *Processing IEEE/ACM Trans on Audio Speech & Language* 2014, 22(4): 778-784.

(上接第 93 页)

- [4] Wang Jian, Deng Wei, Guo Yuntao. New Bayesian combination method for short-term traffic flow forecasting [J]. *Transportation Research Part C: Emerging Technologies* 2014, 43(1): 79-94.
- [5] Kumar K, Parlad M, Katiyar V K. Short term traffic flow prediction for a non urban highway using artificial neural network [J]. *Procedia-Social and Behavioral Sciences* 2014, 104: 755-764.
- [6] Yang Yijiao, Duan Zhenyu. A novel prediction method of traffic flow: least squares support vector machines based on spatial relation [C] // Proc of CICTP 2014: Safe Smart Sustainable Multimodal Transportation Systems. Changsha: ASCE 2014: 1807-1818.
- [7] Xu Yanyun, Kong Qingjie, Klette R *et al.* Accurate and interpretable Bayesian MARS for traffic flow prediction [J]. *IEEE Trans on Intelligent Transportation Systems* 2014, 15(6): 2457-2469.
- [8] 李颖宏, 刘乐敏, 王玉全. 基于组合预测模型的短时交通流预测 [J]. *交通运输系统工程与信息* 2013, 13(2): 32-41.
- [9] Wu Shanhua, Yang Zhongzhen, Zhu Xiacong *et al.* Improved k-nn for short-term traffic forecasting using temporal and spatial information [J]. *Journal of Transportation Engineering* 2014, 140(7): 1-9.
- [10] Hinton G, Osindero S, Teh Y. A fast learning algorithm for deep belief nets [J]. *Neural Computation* 2006, 18(7): 1527-1554.
- [11] Shin H C, Orton M R, Collins D J *et al.* Stacked autoencoders for un-

supervised feature learning and multiple organ detection in a pilot study using 4D patient data [J]. *IEEE Trans on Pattern Analysis and Machine Intelligence* 2013, 35(8): 1930-1943.

- [12] Nascimento J C, Silva J G, Marques J S *et al.* Manifold learning for object tracking with multiple nonlinear models [J]. *IEEE Trans on Image Processing* 2014, 23(4): 1593-1605.
- [13] Kuremoto T, Kimura S, Kobayashi K *et al.* Time series forecasting using a deep belief network with restricted Boltzmann machines [J]. *Neurocomputing* 2014, 137: 47-56.
- [14] Huang Wenhao, Song Guojie, Hong Haikun *et al.* Deep architecture for traffic flow prediction: deep belief networks with multitask learning [J]. *IEEE Trans on Intelligent Transportation Systems* 2014, 15(5): 2191-2201.
- [15] Lyu Yisheng, Duan Yanjie, Kang Wenwen *et al.* Traffic flow prediction with big data: a deep learning approach [J]. *IEEE Trans on Intelligent Transportation Systems* 2014, 16(2): 865-873.
- [16] Fischer A, Igel C. Training restricted Boltzmann machines: an introduction [J]. *Pattern Recognition* 2014, 47(1): 25-39.
- [17] Hinton G E. Training products of experts by minimizing contrastive divergence [J]. *Neural Computation* 2002, 14(8): 1771-1880.
- [18] Gardner E S, McKenzie E. Seasonal exponential smoothing with damped trends [J]. *Management Science*, 1989, 35(3): 372-376.