



(12)发明专利申请

(10)申请公布号 CN 106205126 A

(43)申请公布日 2016. 12. 07

(21)申请号 201610666506.5

(22)申请日 2016.08.12

(71)申请人 北京航空航天大学

地址 100191 北京市海淀区学院路37号

(72)发明人 马晓磊 代壮 吴志海 于海洋

(74)专利代理机构 北京路浩知识产权代理有限公司 11002

代理人 李相雨

(51)Int.Cl.

G08G 1/01(2006.01)

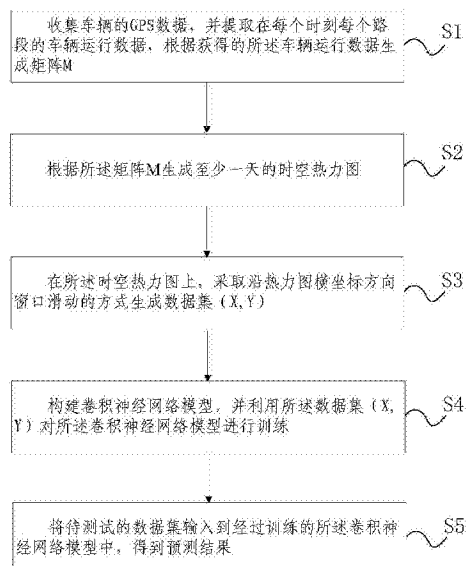
权利要求书2页 说明书8页 附图3页

(54)发明名称

基于卷积神经网络的大规模交通网络拥堵预测方法及装置

(57)摘要

本发明公开一种基于卷积神经网络的大规模交通网络拥堵预测方法及装置,能同时考虑路网车辆速度信息的时序性和空间性,进而可以更准确的预测整个路网交通拥堵状态。所述方法包括:S1、收集车辆的GPS数据,并提取在每个时刻每个路段的车辆运行数据,根据获得的所述车辆运行数据生成矩阵M;S2、根据所述矩阵M生成至少一天的时空热力图;其中,所述时空热力图的横坐标表示时间,纵坐标表示按照空间关系排序的路段ID序列;S3、在所述时空热力图上,采取窗口滑动的方式生成数据集(X,Y);S4、构建卷积神经网络模型,并利用所述数据集(X,Y)对所述卷积神经网络模型进行训练;S5、将待测试的数据集输入到经过训练的所述卷积神经网络模型中,得到预测结果。



1. 一种基于卷积神经网络的大规模交通网络拥堵预测方法,其特征在于,包括:

S1、收集车辆的GPS数据,并提取在每个时刻每个路段的车辆运行数据,根据获得的所述车辆运行数据生成矩阵M,其中,所述车辆运行数据包括车辆平均速度,所述矩阵M中的元素 a_{ij} 表示在时间段i路段j上对应的所述车辆运行数据;

S2、根据所述矩阵M生成至少一天的时空热力图;其中,所述时空热力图的横坐标表示时间,纵坐标表示按照空间关系排序的路段ID序列;

S3、在所述时空热力图上,采取沿热力图横坐标方向窗口滑动的方式生成数据集(X,Y);具体地,将矩阵M表示为 $[m_1, m_2, \dots, m_N]$, m_t 为矩阵第t列数据,N表示一天所有时刻数,当时间单位为T分钟时, $N = \frac{1440}{T}$, 设滑动窗口大小为k个时间单位,则第i个数据 $(X^i, Y^i) = ([m_i, m_{i+1}, \dots, m_{k-1}], [m_k, m_{k+1}, \dots, m_{2k-1}])$, $i = 1 \dots N-2k+1$;

S4、构建卷积神经网络模型,并利用所述数据集(X,Y)对所述卷积神经网络模型进行训练;

S5、将待测试的数据集输入到经过训练的所述卷积神经网络模型中,得到预测结果。

2. 根据权利要求1所述的方法,其特征在于,所述根据获得的所述车辆运行数据生成矩阵M包括:

对获得的所述车辆运行数据进行均值插补,并根据均值插补后的数据生成矩阵M。

3. 根据权利要求1或2所述的方法,其特征在于,所述空间关系包括从北→东→南→西的排序方式。

4. 根据权利要求1所述的方法,其特征在于,所述S4,包括:

S40、打乱数据集(X,Y),并按照预设比例将所述数据集(X,Y)划分为训练集和验证集;

S41、利用当前得到的训练集对所述卷积神经网络模型进行训练,并通过利用当前得到的验证集对训练后的卷积神经网络模型进行验证,判断所述训练后的卷积神经网络模型是否出现过拟合,若出现过拟合,则停止训练,否则,则执行步骤S42;

S42、将当前得到的训练集按照预设比例划分为新的训练集和验证集,并执行步骤S41。

5. 根据权利要求1所述的方法,其特征在于,所述车辆运行数据还包括车辆流量。

6. 一种基于卷积神经网络的大规模交通网络拥堵预测装置,其特征在于,包括:

矩阵生成单元,用于收集车辆的GPS数据,并提取在每个时刻每个路段的车辆运行数据,根据获得的所述车辆运行数据生成矩阵M,其中,所述车辆运行数据包括车辆平均速度,所述矩阵M中的元素 a_{ij} 表示在时间段i路段j上对应的所述车辆运行数据;

热力图生成单元,用于根据所述矩阵M生成至少一天的时空热力图;其中,所述时空热力图的横坐标表示时间,纵坐标表示按照空间关系排序的路段ID序列;

数据集生成单元,用于在所述时空热力图上,采取窗口滑动的方式生成数据集(X,Y);具体地,将矩阵M表示为 $[m_1, m_2, \dots, m_N]$, m_t 为矩阵第t列数据,N表示一天所有时刻数,当时间单位为T分钟时, $N = \frac{1440}{T}$, 设滑动窗口大小为k个时间单位,则第i个数据 $(X^i, Y^i) = ([m_i, m_{i+1}, \dots, m_{k-1}], [m_k, m_{k+1}, \dots, m_{2k-1}])$, $i = 1 \dots N-2k+1$;

训练单元,用于构建卷积神经网络模型,并利用所述数据集(X,Y)对所述卷积神经网络模型进行训练;

预测单元,用于将待测试的数据集输入到经过训练的所述卷积神经网络模型中,得到预测结果。

7.根据权利要求6所述的装置,其特征在于,所述矩阵生成单元,具体用于对获得的所述车辆运行数据进行均值插补,并根据均值插补后的数据生成矩阵M。

8.根据权利要求6或7所述的装置,其特征在于,所述空间关系包括从北→东→南→西的排序方式。

9.根据权利要求6所述的装置,其特征在于,所述训练单元,具体用于:

S40、打乱数据集(X,Y),并按照预设比例将所述数据集(X,Y)划分为训练集和验证集;

S41、利用当前得到的训练集对所述卷积神经网络模型进行训练,并通过利用当前得到的验证集对训练后的卷积神经网络模型进行验证,判断所述训练后的卷积神经网络模型是否出现过拟合,若出现过拟合,则停止训练,否则,则执行步骤S42;

S42、将当前得到的训练集按照预设比例划分为新的训练集和验证集,并执行步骤S41。

10.根据权利要求6所述的装置,其特征在于,所述车辆运行数据还包括车辆流量。

基于卷积神经网络的大规模交通网络拥堵预测方法及装置

技术领域

[0001] 本发明涉及交通信息预测技术领域,具体涉及一种基于卷积神经网络的大规模交通网络拥堵预测方法及装置。

背景技术

[0002] 为了更加准确的预测交通拥堵状况,以为车辆出行提供更加合理的线路规划,十分有必要进行大规模的交通网络拥堵预测,这是因为:(1)在交通网络中,道路的拥堵状况是相互影响的,一个区域的交通拥堵状态与相邻区域的拥堵状态密不可分,因此预测各区域交通动态变化情况需要从网络全局角度出发;(2)单一路段交通拥堵预测具有短视性,最显著的是局部交通预测仅仅借助历史数据,或基于周边有限路段交通状态进行预测,在由单一路段预测扩展到大规模交通网络预测时,运算量大,造成预测效率和精度都无法得到保障,无法满足交通信息服务的实时性和准确性要求。

[0003] 速度是表征交通拥堵的重要特征,因此可以通过预测交通速度判定交通拥堵状态。以往的交通速度预测技术包括:(1)基于传统统计技术进行交通预测,如通过交通特性对速度进行回归预测、用历史平均速度数据预测等;考虑交通数据的周期性和波动性,可以考虑非参数模型,如KNN近邻搜索,通过在历史空间中搜索相似的状态进行预测。但是回归预测普遍存在精度不高问题,KNN存在效率低和精度低问题。(2)基于时间序列进行短时交通速度预测,因为交通速度内在时序性特征,时间序列模型在交通速度预测中得到了大量的应用,主要模型是自回归移动平均模型ARIMA,ARIMA模型能考虑到一个交通速度时间序列的内存规律(移动平均)和时间序列在时间上的启后影响关系(自回归)。为了提高预测的精度,其他的改进的ARIMA模型也有一定应用,如KARIMA模型、季节ARIMA模型、带解释变量的ARIMAX模型等。ARIMA能够在单路段交通速度预测情形下取得一定效果,但是不能同时考虑整个网络,特别是路段之间的相互影响关系,这限制了模型的应用。(3)现代机器学习算法,如支持向量机SVM算法,SVM通过寻找数据的高维可分或近似可分平面,一般可以取得比回归更好的结果,但是算法训练需要更多时间和计算内存,而且不能很好处理多输出问题,无法在大规模网络层面进行应用;人工神经网络ANN也被应用到交通预测之中,而且可以同时预测多个输出,通过网络层的不断学习也可以捕捉到交通数据中存在的一定模式,但是ANN数据驱动的形式并不能很好理解数据的空间关系,而且与深度学习的方法相比,ANN显得太简单以及预测精度太低。

[0004] 以上这些技术能较好处理交通局部的拥堵状态预测问题,但是在预测全网络的交通速度时,以上的模型都需要对每个时刻和每个路段的交通速度信息进行单独建模,当时间跨度增大和交通网络扩大时,所需构建的模型数量极大;而且,这些大量的模型是独立存在的,不能同时考虑整个交通网络的关系。

发明内容

[0005] 有鉴于此,本发明提供一种基于卷积神经网络的大规模交通网络拥堵预测方法及

装置,能同时考虑路网车辆速度信息的时序性和空间性,进而可以更准确的预测整个路网交通拥堵状态。

[0006] 一方面,本发明实施例提出一种基于卷积神经网络的大规模交通网络拥堵预测方法,包括:

[0007] S1、收集车辆的GPS数据,并提取在每个时刻每个路段的车辆运行数据,根据获得的所述车辆运行数据生成矩阵M,其中,所述车辆运行数据包括车辆平均速度,所述矩阵M中的元素 a_{ij} 表示在时间段i路段j上对应的所述车辆运行数据;

[0008] S2、根据所述矩阵M生成至少一天的时空热力图;其中,所述时空热力图的横坐标表示时间,纵坐标表示按照空间关系排序的路段ID序列;

[0009] S3、在所述时空热力图上,采取窗口滑动的方式生成数据集(X,Y);具体地,将矩阵M表示为 $[m_1, m_2, \dots, m_N]$, m_t 为矩阵第t列数据, N表示一天所有时刻数,当时间单位为T分钟时, $N = \frac{1440}{T}$, 设滑动窗口大小为k个时间单位,则第i个数据 $(X^i, Y^i) = ([m_i, m_{i+1}, \dots, m_{k-1}], [m_k, m_{k+1}, \dots, m_{2k-1}])$, $i = 1 \dots N-2k+1$;

[0010] S4、构建卷积神经网络模型,并利用所述数据集(X,Y)对所述卷积神经网络模型进行训练;

[0011] S5、将待测试的数据集输入到经过训练的所述卷积神经网络模型中,得到预测结果。

[0012] 另一方面,本发明实施例提出一种基于卷积神经网络的大规模交通网络拥堵预测装置,包括:

[0013] 矩阵生成单元,用于收集车辆的GPS数据,并提取在每个时刻每个路段的车辆运行数据,根据获得的所述车辆运行数据生成矩阵M,其中,所述车辆运行数据包括车辆平均速度,所述矩阵M中的元素 a_{ij} 表示在时间段i路段j上对应的所述车辆运行数据;

[0014] 热力图生成单元,用于根据所述矩阵M生成至少一天的时空热力图;其中,所述时空热力图的横坐标表示时间,纵坐标表示按照空间关系排序的路段ID序列;

[0015] 数据集生成单元,用于在所述时空热力图上,采取窗口滑动的方式生成数据集(X,Y);具体地,将矩阵M表示为 $[m_1, m_2, \dots, m_N]$, m_t 为矩阵第t列数据, N表示一天所有时刻数,当时间单位为T分钟时, $N = \frac{1440}{T}$, 设滑动窗口大小为k个时间单位,则第i个数据 $(X^i, Y^i) = ([m_i, m_{i+1}, \dots, m_{k-1}], [m_k, m_{k+1}, \dots, m_{2k-1}])$, $i = 1 \dots N-2k+1$;

[0016] 训练单元,用于构建卷积神经网络模型,并利用所述数据集(X,Y)对所述卷积神经网络模型进行训练;

[0017] 预测单元,用于将待测试的数据集输入到经过训练的所述卷积神经网络模型中,得到预测结果。

[0018] 本发明具有如下有益效果:

[0019] 1、本发明通过时空图的方式来处理网络车辆速度信息,生成速度热力图,整合了车辆速度信息在时间和空间上的关系,表达直观形象,可以帮助交通管理部门更加直观的了解路网的交通信息;

[0020] 2、本发明考虑了交通网络信息的时序性和空间性,并能通过卷积神经网络大规模

实施,具有较好的适用性和较高的预测精度,这对于减小道路交通拥堵、提高道路运行效率、减小城市二氧化碳排放以及城市智能交通的实现都有重要意义;

[0021] 3、本发明不需要大量的数据预处理,操作简单,对较大交通网络学习效率高,不需要对每个时刻每个路段进行单独建模,可基于TensorFlow等分布式平台进行实现,提高模型计算效率。

附图说明

[0022] 图1为本发明基于卷积神经网络的大规模交通网络拥堵预测方法一实施例的流程示意图;

[0023] 图2为本发明所述的整合了交通路网车辆速度信息时间性和空间性的热力图;

[0024] 图3为本发明所述的基于卷积神经网络CNN进行交通网络车辆速度信息预测的原理图;

[0025] 图4为本发明基于卷积神经网络的大规模交通网络拥堵预测装置一实施例的结构示意图。

具体实施方式

[0026] 为使本发明实施例的目的、技术方案和优点更加清楚,下面将结合本发明实施例中的附图,对本发明实施例中的技术方案进行清楚地描述,显然,所描述的实施例是本发明一部分实施例,而不是全部的实施例。基于本发明中的实施例,本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施例,都属于本发明保护的范围。

[0027] 参看图1,本实施例公开一种基于卷积神经网络的大规模交通网络拥堵预测方法,包括:

[0028] S1、收集车辆的GPS数据,并提取在每个时刻每个路段的车辆运行数据,根据获得的所述车辆运行数据生成矩阵M,其中,所述车辆运行数据包括车辆平均速度,所述矩阵M中的元素 a_{ij} 表示在时间段i路段j上对应的所述车辆运行数据;

[0029] 生成矩阵M的过程伴随着对数据进行时空上的均值插补,具体地,当需要在一个时间 \times 空间为 3×3 的范围内对数据进行均值插补时,设矩阵

$$[0030] \quad M = \begin{pmatrix} a_{11}, a_{12}, a_{13} \\ a_{21}, a_{22}, a_{23} \\ a_{31}, a_{32}, a_{33} \end{pmatrix} = \begin{pmatrix} 42, 43, 40 \\ 35, ?, 40 \\ 33, 41, 35 \end{pmatrix} \quad (3)$$

[0031] 其中行为时间单元 $[1, 2, 3]$,列为路段id $[1, 2, 3]$,那么 a_{ij} 表示在时间段i路段j上车辆的平均速度,当 a_{22} 缺失时其在时空上的均值插补为

$$[0032] \quad \hat{a}_{22} = \frac{1}{8}(42 + 43 + 40 + 35 + 40 + 33 + 41 + 35) = 38.625 \quad (4)$$

[0033] S2、根据所述矩阵M生成至少一天的时空热力图;其中,所述时空热力图的横坐标表示时间,纵坐标表示按照空间关系排序的路段ID序列;

[0034] 如图2所示为本发明所述的整合了交通路网车辆速度信息时间性和空间性的热力图,热力图的横坐标方向为时间,按照每1个时间单位(可以为2分钟)的间隔递增,时间跨度为一天;纵坐标为按照空间关系排序的路网路段id序列。空间关系可采用从北 \rightarrow 东 \rightarrow 南 \rightarrow

西排序方式,在其他复杂的交通路网中,还可以采用多种空间方式排序,如从北到南的横向扫描方式,所采用的空间关系排序方式应尽可能的保留路网的空间信息,最后将每一种排序结果作为图像处理的一个通道;每天的车辆速度热力图都按照相同的方式生成。

[0035] S3、在所述时空热力图上,采取窗口滑动的方式生成数据集(X,Y);

[0036] 具体地,对某一天而言,当时间单位为2分钟时,热力图矩阵M为 $[m_1, m_2, \dots, m_{720}]$;在窗口滑动过程中保持纵坐标的路段ID序列不变,若采用窗口为10个时间单位,第i个训练样本 $(X^i, Y^i) = ([m_i, m_{i+1}, \dots, m_{i+9}], [m_{i+10}, m_{i+11}, \dots, m_{i+19}])$, $i = 1 \dots 701$ 。

[0037] 因此,每一天生成的训练样本数目为 $720 - 10 - 10 + 1 = 701$,数据集(X,Y)中X矩阵大小为 $(701, 1, n, 10)$,Y矩阵大小为 $(701, 1, n, 10)$,n为交通网络的路段总数,数字1表示图像有一个通道,当通过多种空间表达方式时,通道数会相应增加,比如,当所述车辆运行数据还包括车辆流量时,通道数为2。当数据包含d天的数据时,数据集(X,Y)中X矩阵大小为 $(701d, 1, n, 10)$,Y矩阵大小为 $(701d, 1, n, 10)$ 。数据集的生成采取窗口滑动的方式,这保证了CNN深度学习模式有大量的可训练样本。

[0038] S4、构建卷积神经网络模型,并利用所述数据集(X,Y)对所述卷积神经网络模型进行训练;

[0039] 卷积神经网络模型主要由卷积层、池化层、全连接层组成,在不同的卷积神经网络结构中,三者的组合方式和数量并不相同,本发明在经过实践并保持模型学习能力和训练速度的基础上,采用了如图3的结构,但是本发明并不仅限于这样的结构,其他CNN模型(卷积神经网络模型)可能在卷积层和池化层的组合方式和数量上不同。下面按照如图3的结构详细讲解,为了方便说明,以下的讲解以一个样本为例,样本大小为 $(1, n, 10)$ 。

[0040] 第一层是一个 $60 \times 3 \times 3$ 的卷积层,该卷积层含有60个不同的 3×3 大小的卷积核,不同的卷积核可以学习到图像的60种不同抽象特征。设卷积核

$$[0041] \quad f = \begin{pmatrix} w_{11}, w_{12}, w_{13} \\ w_{21}, w_{22}, w_{23} \\ w_{31}, w_{32}, w_{33} \end{pmatrix} \quad (7)$$

[0042] 图像中一个 3×3 区域

$$[0043] \quad m = \begin{pmatrix} m_{11}, m_{12}, m_{13} \\ m_{21}, m_{22}, m_{23} \\ m_{31}, m_{32}, m_{33} \end{pmatrix} \quad (8)$$

[0044] 当卷积核f作用于m时,可得卷积值为:

$$[0045] \quad c = w_{11}m_{11} + w_{12}m_{12} + w_{13}m_{13} + w_{21}m_{21} + w_{22}m_{22} + w_{23}m_{23} + w_{31}m_{31} + w_{32}m_{32} + w_{33}m_{33} \quad (9)$$

[0046] 上式中, w_{ij} 为卷积核系数, m_{ij} 为相应的卷积图像值, $i, j \in (1, 2, 3)$ 。

[0047] 卷积核通过滑窗的方式滑动卷积图像,设置卷积后边界大小不变,样本的大小变为 $(60, n, 10)$;得到所有卷积值通过RELU函数 $g(x)$ 激活,激活值后的矩阵作为该层的输出。RELU函数为:

$$[0048] \quad g(x) = \begin{cases} x & \text{当 } x \geq 0 \\ 0 & \text{当 } x < 0 \end{cases} \quad (10)$$

[0049] 第二层是一个2*2的池化层,池化层能对数据进行降维,大大减少模型训练的时间。对图像中一个2*2区域

$$[0050] \quad m = \begin{pmatrix} m_{11}, m_{12} \\ m_{21}, m_{22} \end{pmatrix} \quad (11)$$

[0051] 经过池化层作用后,对应的值变为

$$[0052] \quad \text{maxpooling}(m) = \max(m_{11}, m_{12}, m_{21}, m_{22}) \quad (12)$$

[0053] 将池化过程运用到(60,n,10)的样本中,得到新矩阵(60,n/2,5),这是第二层的输出。

[0054] 第三层是一个60*3*3的卷积层,激活函数为RELU,设置边界大小不变,运用第一步中的计算过程,得到新输出(60,n/2,5),这将使得学习到的特征抽象程度更高。

[0055] 第四层是一个60*3*3的卷积层,激活函数为RELU,设置边界大小不变,运用第一步中的计算过程,得到新输出(60,n/2,5),这将使得学习到的特征抽象程度更高。

[0056] 第五层是一个2*2的池化层,将池化层作用于第四层的输出,得到新输出(60,n/4,3)。

[0057] 第六层是一个数据转换层,将第五层输出的矩阵转换为一个(60*n/4*3,1)的向量,这为之后的全连接层作数据准备。

[0058] 第七层是一个全连接层,即通过(60*n/4*3,1)向量预测n个路段在未来10个时间单位内的速度,预测输出为(10n,1)。

[0059] 在具体应用中,可以采用深度学习框架,如Caffe,Theano构建CNN模型,为了加速计算过程,调用计算机GPU计算;为了防止模型过拟合,采用Early Stopping策略,其将训练集按照用户指定的比例(如8:2)分为新的训练集和验证集,模型训练时只采用新的训练集,且在每轮模型训练结束之后验证模型在验证集上的表现,如监听均方误差MSE的变化,当MSE不断变小,说明模型通过学习预测能力不断增强,此时应当继续训练,当MSE开始增大时,说明模型开始出现过拟合,应当停止训练。其中,MSE的计算公式为:

$$[0060] \quad MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (13)$$

[0061] 其中, y_i 与 \hat{y}_i 分别为第i个路段的真实数据与预测结果。

[0062] 本发明采用卷积神经网络CNN学习热力图,通过卷积神经网络的卷积过程和池化过程将速度热力图抽象为单一向量v,通过向量v可对未来交通路网车辆速度信息进行预测。

[0063] S5、将待测试的数据集输入到经过训练的所述卷积神经网络模型中,得到预测结果。

[0064] 如图3为本发明所述的基于卷积神经网络CNN进行交通网络车辆速度信息预测的原理图,将待测试的数据(比如前20分钟的二环速度)集输入CNN模型,待测试的数据依次经卷积层、池化层、卷积层、池化层、全连接层处理,得到预测结果,比如可以为未来20分钟的二环速度。

[0065] 参看图4,本实施例公开一种基于卷积神经网络的大规模交通网络拥堵预测装置,包括:

[0066] 矩阵生成单元1,用于收集车辆的GPS数据,并提取在每个时刻每个路段的车辆运

行数据,根据获得的所述车辆运行数据生成矩阵M,其中,所述车辆运行数据包括车辆平均速度,所述矩阵M中的元素 a_{ij} 表示在时间段i路段j上对应的所述车辆运行数据;

[0067] 在具体应用中,所述车辆运行数据还可以包括车辆流量。所述矩阵生成单元,具体用于对获得的所述车辆运行数据进行均值插补,并根据均值插补后的数据生成矩阵M。

[0068] 热力图生成单元2,用于根据所述矩阵M生成至少一天的时空热力图;其中,所述时空热力图的横坐标表示时间,纵坐标表示按照空间关系排序的路段ID序列;

[0069] 具体地,所述空间关系可以包括从北→东→南→西的排序方式。

[0070] 数据集生成单元3,用于在所述时空热力图上,采取窗口滑动的方式生成数据集(X,Y);具体地,将矩阵M表示为 $[m_1, m_2, \dots, m_N]$, m_t 为矩阵第t列数据,N表示一天所有时刻

数,当时间单位为T分钟时, $N = \frac{1440}{T}$,设滑动窗口大小为k个时间单位,则第i个数据(X^i, Y^i)= $([m_i, m_{i+1}, \dots, m_{k-1}], [m_k, m_{k+1}, \dots, m_{2k-1}])$, $i = 1 \dots N-2k+1$;

[0071] 训练单元4,用于构建卷积神经网络模型,并利用所述数据集(X,Y)对所述卷积神经网络模型进行训练;

[0072] 所述训练单元,具体用于:

[0073] S40、打乱数据集(X,Y),并按照预设比例将所述数据集(X,Y)划分为训练集和验证集;

[0074] S41、利用当前得到的训练集对所述卷积神经网络模型进行训练,并通过利用当前得到的验证集对训练后的卷积神经网络模型进行验证,判断所述训练后的卷积神经网络模型是否出现过拟合,若出现过拟合,则停止训练,否则,则执行步骤S42;

[0075] S42、将当前得到的训练集按照预设比例划分为新的训练集和验证集,并执行步骤S41。

[0076] 预测单元5,用于将待测试的数据集输入到经过训练的所述卷积神经网络模型中,得到预测结果。

[0077] 以下以北京二环为例,进一步实例说明本发明的应用。

[0078] 第一步,收集北京市二环的车辆速度信息,包含2015年05月25日到2016年06月30日共37天的全天车辆速度数据,共236个路段。由于数据存在部分缺失,因此在时间×空间为 3×3 的范围内对数据进行均值插补,缺失值填补能够减小离异点对模型的影响。

[0079] 第二步,生成热力图如图2,其中x轴为时间,取值范围为 $[1, 720]$,一个刻度代表一个时间单位(2分钟),纵坐标为北京市二环的路段ID,所有路段按照从北→东→南→西的空间顺序排列,图像中颜色代表了道路的拥堵程度,颜色越深表示拥堵越严重。

[0080] 第三步,生成训练集和测试集。在实例中通过前10个时间单位的交通网络车辆速度来预测后10个时间单位的交通网络车辆速度,对每一天而言可以得到样本701份,进而在37天中可以得到样本25937份,按照比例8:2将以上数据分为训练集和测试集,因此训练集共有样本20750份,测试集有数据5187份。

[0081] 第四步,构建卷积神经网络模型。Keras是一个可基于Theano和TensorFlow的深度学习框架,Keras通过训练层叠加的方式使用构建深度学习模型非常简单,且Keras能通过Theano或TensorFlow调用系统GPU进行模型计算,因此在实例中选择Keras作为搭建模型的框架。卷积神经网络模型的构建完成了由数据输出到数据预测输出的全转换过程,表1总结

了模型中每一层输出矩阵大小,以及要学习的参数规模。

[0082] 表1卷积神经网络结构说明

	层数	名称	参数说明	输出矩阵大小	参数数量
[0083]	单样本 输入矩阵 大小	(1,236,10)			
	第一层	卷积层	卷积核为(60,3,3)	(60,236,10)	540
	第二层	池化层	(2,2)	(60,118,5)	0
[0084]	第三层	卷积层	卷积核为(60,3,3)	(60,118,5)	540
	第四层	卷积层	卷积核为(60,3,3)	(60,118,5)	540
	第五层	池化层	(2,2)	(60,59,3)	0
	第六层	数据转换层	——	(10620,1)	0
	第七层	全连接层	——	(2360,1)	25063200
	单样本 输出矩阵 大小	(2360,1)			

[0085] 第五步,模型训练。配置Keras在GPU上运行,并实施EarlyStopping策略,将20750份训练样本按照8:2比例分为16600份训练集和4150份验证集,在模型每轮运行结束时检验模型在验证集上的MSE,当MSE不降反升时表明训练开始出现过拟合,此时停止训练,并以现在的模型为最终模型训练结果;在实例中,训练在第23回合被Early Stopping。

[0086] 第六步,模型预测并计算预测结果的均方误差。将测试集5187份数据输入第五步训练好的模型中,得到结果如表2。为了说明该发明的效果,表2还给出了其他算法的结果,可以看出,在测试集上CNN模型的MSE结果最好,为44.71,该结果比其他算法提高2倍以上。Extra trees算法在训练集上MSE为0,但是其在测试集中MSE增至80.76,说明Extra trees出现了明显的过拟合现象。

[0087] 表2各算法在训练集和测试集上的MSE

[0088]	算法	训 练 集 MSE	测试集 MSE
	OLS	77.83	111.56
[0089]	Ridge OLS	84.84	101.26
	KNN	160.59	376.94
	Extra trees	0	80.76
	SVR	87.35	144.56
	ANN	228.20	225.47
	CNN	37.54	44.71

[0090] 虽然结合附图描述了本发明的实施方式,但是本领域技术人员可以在不脱离本发明的精神和范围的情况下做出各种修改和变型,这样的修改和变型均落入由所附权利要求所限定的范围之内。

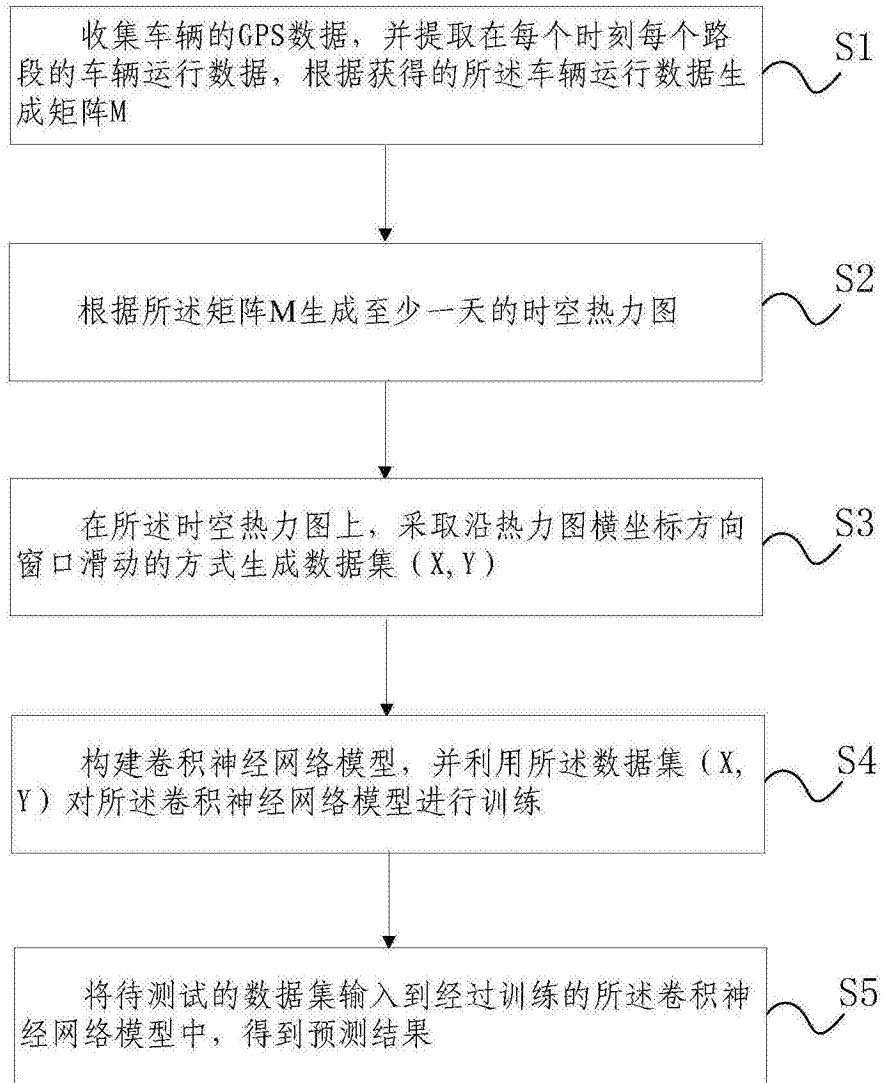


图1




图2




图3

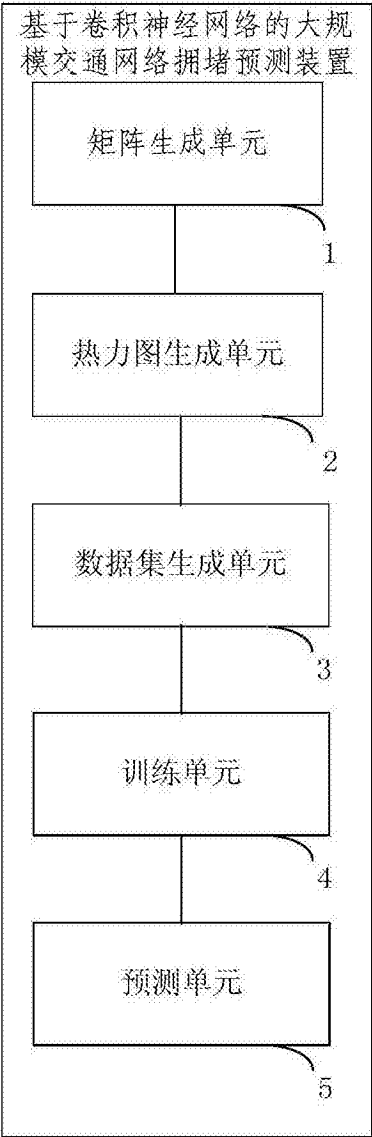


图4